

Buzy AI

Système d'exploitation autonome pour les organisations

Destin Bir

GDG Gemma 4 Hackathon 2026

Le problème


Les entreprises produisent chaque jour des **contrats**, **factures**, **comptes-rendus**, **tableaux de bord** — dispersés entre PDF, tableurs, images et enregistrements audio.

- Extraire des informations exploitables prend des **heures de travail manuel**
- Les documents sont dans **des formats hétérogènes** non connectés

Exemples de questions :

“Quel fournisseur représente le plus grand risque opérationnel le trimestre prochain ?”

“Faut-il renouveler ce contrat ?”




Buzy AI est un système de raisonnement métier multimodal qui transforme des documents bruts en décisions structurées et explicables.

1. **Ingestion** de documents (PDF, DOCX, TXT), images et audio
2. **Extraction** de faits structurés via Gemma 4 Vision-Language
3. **Construction** d'une base de connaissances légère
4. **Recherche** des preuves pertinentes pour chaque question
5. **Génération** de recommandations structurées avec sources




Architecture du pipeline décisionnel



- Données brutes → analyse multimodale → extraction → base de connaissances → raisonnement → recommandations

Pipeline d'extraction de connaissances



- Entités extraites : fournisseurs, contrats, factures, projets, risques
- Chaque fait est rattaché à son document source

Capacités Vision-Language de Gemma 4 :

- Analyse de factures, reçus, contrats scannés
- Extraction JSON structurée (fournisseur, montant, dates)
- Traitement de tableaux de bord et captures d'écran

Extraction de facture

Entrée : image de facture

Sortie : { "supplieur": "LOGISTIQUE & FOURNITURES SARL",


"invoice_id": "INV-8942-FR",

"due_date": "18 Mai 2026",


"amount": "650,00 €" }

Facture 2 : Fournitures de Bureau			
LOGISTIQUE & FOURNITURES SARL			
45 Avenue Jean Jaurès, 69007 Lyon			
Siret : 987 654 321 00045			
Émis le : 18 Mai 2026			
Facture N° : INV-8942-FR			
Client : Agence Communication Horizon			
Date d'échéance : 18 Juin 2026			
Date de paiement : 20 Mai 2026 (Payé)			
Description	Quantité	Prix Unitaire HT	Total HT
Papeterie & Cartouches d'encre	1 Lot	240,00 €	240,00 €
Imprimante Scanner Multifonction	1	410,00 €	410,00 €
...			
Total HT : 650,00 €			
TVA (20%) : 130,00 €			
Net à payer (TTC) : 780,00 €			

Grphe de connaissances mtier



Fine-tuning LoRA



- Adaptateurs LoRA de **rang 8**
- Couches langage seulement (vision gelée)
- 4 exemples de raisonnement structuré
- **20 époques** d'entraînement
- **0,25%** des paramètres (12,6M / 5,1Mds)
- Perte finale : **0,299**
- Kaggle (2× T4, ~57s)

Structure du jeu de données de raisonnement

Chaque exemple suit un schéma JSON strict :

Entrée

Question métier :

Quel fournisseur présente
le plus grand risque ?

Faits pertinents :

- 18 jours de retard de paiement
- 2 projets dépendent d'Atlas
- Contrat expire dans 27 jours
- Instabilité de livraison signalée

Sortie

```
{  
  "evidence": [...],  
  "reasoning": [...],  
  "confidence": 0.82,  
  "business_impact": "...",  
  "recommended_actions": [...]  
}
```

Raisonnement augmenté par récupération



- Recherche par mot-clé dans la base de connaissances
- Gemma 4 génère une chaîne de raisonnement explicite
- **Explicable** : preuves → raisonnement → confiance → impact → actions

Question : Quel fournisseur présente le plus grand risque opérationnel ?


- **Preuves :** Retard de 18 jours, instabilité livraison (2 réunions), contrat expire dans 27 jours
- **Raisonnement :** Retards répétés + dépendance exclusive du Projet Phoenix
- **Confiance :** Élevée (0,82)

Impact : Risque de retard de 2 semaines pour le Projet Phoenix

Actions :

1. Négocier le renouvellement immédiatement
2. Qualifier un fournisseur secondaire
3. Renforcer le processus d'approbation des paiements

Agent IA avec utilisation d'outils



- Gemma 4 choisit l'outil à appeler selon la question posée
- Outils : `get_invoice_status()`, `get_contract_expiry()`
- Le résultat de l'outil est réinjecté pour générer la réponse finale

Anglais

"Which supplier represents the highest operational risk next quarter?"

→ JSON structuré avec preuves, raisonnement, confiance

Français

"Quel fournisseur représente le plus grand risque opérationnel le trimestre prochain ?"

→ Même structure JSON en français

Même qualité de raisonnement dans les deux langues
(Testé avec des documents métier français)

Analyse multimodale interactive :

- Import d'images, PDF/DOCX/TXT, audio
- Posez n'importe quelle question métier
- Exemples en un clic (facture, contrat, réunion)
- Rapport Markdown avec sources citées

`python app.py`

→ `http://localhost:7860`

Fonctionnalités :

- Chargement paresseux des modèles
- Barre de progression Gradio
- Détection automatique CUDA
- ASR Whisper pour l'audio
- Galerie des images importées

Structure du projet

```
Buzy_Multimodal_Gemma/  
  app.py  
  requirements.txt  
  pyproject.toml  
  LICENSE  
  src/  
    __init__.py  
    model.py  
    loaders.py  
    prompt.py  
    inference.py
```

```
notebooks/  
  buzy-ai-gemma4-lora.ipynb  
assets/  
  architecture.png  
  business_decision_pipeline.png  
  knowledge_extraction_pipeline.png  
  business_knowledge_graph.png  
  ai_agent_workflow.png  
  retrieval_augmented_reasoning.png  
  LoRa_finetuning.png  
  thumbnail.png
```

Couche	Technologie
Modèle de base	Gemma 4 (E2B-it) quantifié 4-bit
Fine-tuning	LoRA via Unsloth
Poids entraînés	DestinBir/buzy-ai-gemma4-lora
Application	Gradio
Reconnaissance vocale	Whisper (openai/whisper-small)
Parsing documents	PyMuPDF, python-docx
Entraînement	TRL (SFTTrainer)
Plateforme	Kaggle (2× T4 GPU)

Métrique	Valeur
Modèle de base	Gemma 4 (E2B-it)
Méthode de fine-tuning	LoRA (rang 8)
Paramètres entraînés	12,6M / 5,1Mds (0,25%)
Époques d'entraînement	20
Perte finale	0,299
Temps d'entraînement	~57s (2× T4)
Dispositif d'inférence	CPU ou CUDA
Poids du modèle	Hugging Face

Hugging Face – DestinBir/buzy-ai-gemma4-lora

github github.com/DestinBir/Buzy_Multimodal_Gemma

huggingface huggingface.co/DestinBir/buzy-ai-gemma4-lora

kaggle kaggle.com/destinbir1/buzy-ai-gemma4-lora

Merci !

GDG Gemma 4 Hackathon 2026

Propulsé par Gemma 4 de Google